

Informe Proyecto Eliminación Inteligente de una Interferencia Tonal en una Señal de Voz

Alegría Bernate Daniel Mateo 1401658
Valero Ediem Andres 1401608

Resumen— En este proyecto se implementó una metodología para identificar y reducir una interferencia tonal presente en una señal de voz mediante la combinación de técnicas de procesamiento digital de señales e inteligencia artificial. Inicialmente, se realizó un análisis de la señal en los dominios del tiempo y la frecuencia, complementado con un espectrograma, mediante el cual se identificó una componente tonal estacionaria alrededor de 389 Hz. A partir de esta estimación se diseñaron filtros rechaza-banda FIR con ventana de Blackman e IIR Butterworth para atenuar la interferencia. Posteriormente, se empleó el algoritmo DBSCAN sobre el espectrograma con el propósito de localizar automáticamente la frecuencia de la interferencia, obteniendo una estimación de 387,60 Hz y un error relativo de 0,36 % respecto a la medición manual de 389 Hz. Con esta frecuencia se rediseñaron los filtros y se evaluó su desempeño mediante una máscara espectral y el indicador R, definido como la relación entre la energía residual de la interferencia y la energía conservada de la señal. Los resultados mostraron que ambas técnicas permitieron reducir significativamente la interferencia, pero el filtro FIR Blackman diseñado a partir de la frecuencia obtenida mediante DBSCAN presentó el menor indicador R, con un valor aproximado de 0,06412, y una reducción del 78,04 % respecto a la señal original. Por tanto, esta alternativa fue seleccionada como la solución de mejor desempeño bajo los criterios cuantitativos establecidos.

Palabras clave: nterferencia tonal; procesamiento digital de señales; señal de voz; filtro FIR; ventana de Blackman; filtro IIR; Butterworth; DBSCAN; espectrograma; inteligencia artificial; filtrado rechaza-banda; análisis espectral.

Abstract— This project implemented a methodology to identify and reduce a tonal interference present in a speech signal by combining digital signal processing techniques and artificial intelligence. Initially, the signal was analyzed in the time and frequency domains, complemented by a spectrogram, which allowed the identification of a stationary tonal component around 389 Hz. Based on this estimation, FIR band-stop filters using a Blackman window and IIR Butterworth filters were designed to attenuate the interference. Subsequently, the DBSCAN algorithm was applied to the spectrogram to automatically locate the interference frequency, obtaining an estimated frequency of 387.60 Hz and a relative error of 0.36% compared with the manually identified frequency of 389 Hz. Using this automatically estimated frequency, the filters were redesigned and their performance was evaluated through a spectral mask and the R performance indicator, defined as the ratio between the residual interference energy and the preserved signal energy. The results showed that both filtering techniques significantly reduced the interference; however, the FIR Blackman filter designed using the frequency detected by DBSCAN achieved the lowest R value, approximately 0.06412, corresponding to a 78.04% reduction relative to the original signal. Therefore, this alternative was selected as the best-performing solution according to the established quantitative criteria.

Keywords: Tonal interference; digital signal processing; speech signal; FIR filter; Blackman window; IIR filter; Butterworth filter; DBSCAN; spectrogram; artificial intelligence; band-stop filtering; spectral analysis.

I. OBJETIVOS

A. Objetivo General

Implementar una metodología para identificar y reducir interferencias tonales en señales de voz, combinando procesamiento digital de señales e inteligencia artificial para seleccionar la mejor solución bajo criterios objetivos

B. Objetivos Específicos

- Analizar la señal en los dominios del tiempo y la frecuencia para proponer una hipótesis inicial sobre la ubicación de la interferencia
- Diseñar filtros FIR e IIR con parámetros técnicos justificados para eliminar de forma efectiva el ruido tonal detectado
- Aplicar el algoritmo DBSCAN para localizar automáticamente la frecuencia de la interferencia y apoyar el diseño del filtrado
- Evaluar el desempeño de las soluciones mediante indicadores matemáticos para seleccionar la alternativa más eficiente

II. PROCEDIMIENTO

- En primer lugar, se realizó un análisis exploratorio de la señal de audio suministrada en el dominio del tiempo, el espectro en escala lineal y el espectrograma. A partir de estas representaciones visuales, se formuló una hipótesis inicial sobre la ubicación de la interferencia tonal, fundamentada en la observación de componentes constantes en la amplitud y picos específicos en el espectro.
- Posteriormente, se seleccionaron y diseñaron dos tipos de filtrado digital: FIR e IIR. Estos filtros se configuraron teniendo en cuenta la ubicación de la interferencia establecida previamente mediante las gráficas, permitiendo así una primera aproximación a la limpieza de la señal, tras lo cual se exportaron los archivos de audio resultantes para su posterior análisis comparativo.
- En una etapa siguiente, se utilizó el algoritmo de inteligencia artificial DBSCAN sobre el espectrograma para localizar automáticamente la frecuencia exacta de la interferencia. Con este nuevo dato, se procedió a rediseñar los filtros integrando la información suministrada por la IA, lo cual permitió una mayor precisión en el procesamiento y la generación de nuevos archivos de audio filtrados.


- Finalmente, se evaluó el desempeño de las soluciones calculando la energía residual de la interferencia mediante una ventana de 100 Hz centrada en la frecuencia detectada, junto con la energía conservada de la señal ubicada fuera de dicho rango. A partir de estos valores, se obtuvo el indicador de desempeño R, el cual permitió realizar una comparación objetiva para seleccionar la alternativa de filtrado más eficiente.

III. RESULTADOS EXPERIMENTALES

- Inicialmente se desarrolló un script en Python utilizando librerías especializadas como Numpy, Matplotlib, SoundFile y Scipy. Este código permitió realizar el procesamiento digital de la señal de voz suministrada, facilitando la generación de representaciones visuales precisas y la extracción de parámetros fundamentales para la identificación de la interferencia tonal.


```
import numpy as np
import matplotlib.pyplot as plt
import soundfile as sf
from scipy.signal import spectrogram
x, fs = sf.read("D:/Users/ASUS/Downloads/audio_grupo_02.wav")
if x.ndim > 1:
    x = x[:, 0]
t = np.arange(len(x)) / fs
#f_nyquist = fs / 2
# Espectro en escala lineal
n = len(x)
freqs = np.fft.rfftfreq(n, d=1 / fs)
X = np.fft.rfft(x)
mag = np.abs(X)
# Espectrograma
f, t_spec, Sxx = spectrogram(x, fs=fs, nperseg=256, noverlap=128)
vmin, vmax = -120, -20
fig, axes = plt.subplots(3, 1, figsize=(12, 10))
# 1) Señal en el dominio del tiempo
axes[0].plot(t, x, color='b', linewidth=1.0, alpha=0.7)
axes[0].set_title('Señal en el dominio del tiempo')
axes[0].set_xlabel('Tiempo [s]')
axes[0].set_ylabel('Amplitud')
axes[0].grid(True, alpha=0.3)
# 2) Espectro de la señal en escala lineal
axes[1].plot(freqs, mag, color='r', linewidth=1.0)
axes[1].set_title('Espectro de la señal (escala lineal)')
axes[1].set_xlabel('Frecuencia [Hz]')
axes[1].set_ylabel('|X(f)|')
axes[1].set_xlim([0, 2000])
axes[1].grid(True, alpha=0.3)
# 3) Espectrograma
im = axes[2].pcolormesh(t_spec, f, 10 * np.log10(Sxx + 1e-12),
                        shading='gouraud', vmin=vmin, vmax=vmax)
axes[2].set_title('Espectrograma de la señal')
axes[2].set_xlabel('Tiempo [s]')
axes[2].set_ylabel('Frecuencia [Hz]')
axes[2].set_ylim([0, 2000])
fig.colorbar(im, ax=axes[2], label='Magnitud [dB]')
plt.tight_layout()
plt.show()
```

Posteriormente, al analizar la señal en el dominio del tiempo




Gráfica 1. Señal General Dominio del Tiempo


se observó una amplitud constante de aproximadamente $\pm 0,05$ a lo largo de los casi 7,5s de duración del audio. Mediante el uso de herramientas de visualización, se realizó un acercamiento que permitió confirmar la existencia de una señal periódica aparentemente pura



Gráfica 2. Visualización del Tono en el tiempo




Gráfica 3. Acercamiento al Tono en el Tiempo



Gráfica 4. Acercamiento al Tono en otro instante de Tiempo

la cual persiste de forma ininterrumpida durante todo el registro, lo que constituye el primer indicio de una interferencia de tipo tonal.

- En cuanto al espectro de la señal en escala lineal



Gráfica 5. Espectro General Señal

se identificó una componente de magnitud prominente situada en el rango entre los 250Hz y los 500Hz. Un análisis detallado de esta región permitió localizar con precisión el pico de energía



Gráfica 6. Acercamiento al Tono en la Frecuencia



Gráfica 7. Acercamiento al Tono en la Frecuencia




Gráfica 8. Mayor Acercamiento al Tono en la Frecuencia

en los 389Hz, ajustando la percepción visual inicial que situaba el tono cerca de los 385Hz, y confirmando así la presencia de una interferencia de frecuencia única y fija.


- Con base en estos resultados, se formula la hipótesis de que la señal de audio se encuentra afectada por una interferencia tonal pura y estacionaria con una frecuencia aproximada de 389 Hz. Esta suposición se justifica por la concordancia entre la oscilación

periódica de amplitud constante observada en el dominio del tiempo y el pico de magnitud dominante identificado con precisión en el análisis espectral


- Finalmente, el espectrograma ratificó los hallazgos anteriores al mostrar una franja de color intensa, representativa de niveles altos de decibelios, de manera persistente por debajo de los 500 Hz a lo largo de toda la extensión temporal.



Gráfica 9. Espectrograma Señal General



Gráfica 10. Acercamiento al Tono en la Concentración de Energía



Gráfica 11. Acercamiento al Tono en la Concentración de Energía

Esta visualización permitió verificar que la interferencia es de carácter estacionario, ya que su distribución espectral no varía en el tiempo, lo que fundamenta la formulación de la hipótesis inicial necesaria para el posterior diseño de los filtros.

- Para la implementación del filtro FIR, se optó por el método de ventaneo de Blackman configurado como un filtro de tipo rechaza banda. Coherente con la hipótesis formulada, el diseño se basó en una ventana de 100Hz centrada en la ubicación estimada del tono (389 Hz), lo que define un rango de supresión entre 339Hz y 439Hz. De este modo, los parámetros quedan establecidos de la siguiente manera:

$$339\text{Hz} \leq f_T \leq 439\text{Hz}$$

$$\Delta f_T = 439\text{Hz} - 339\text{Hz} = 100\text{Hz}$$

Esta configuración permite asegurar que la energía de la interferencia quede contenida dentro del rango de rechazo del filtro, facilitando su eliminación efectiva. El código implementado para el diseño y aplicación del filtro FIR con ventana de Blackman es el siguiente:

```
import numpy as np
import matplotlib.pyplot as plt
import librosa
from scipy.signal import filtfilt, spectrogram, firwin, freqz
from IPython.display import Audio, display
#Lectura del audio
x_ruidosa_filepath = 'D:/Users/ASUS/Downloads/audio_grupo_02.wav'
x, fs=librosa.load(x_ruidosa_filepath, sr=None)
ancho_banda=50
lim_inf=389-ancho_banda
lim_sup=389+ancho_banda
ventana=lim_sup-lim_inf
N=int((5.8*fs)/ventana)
if (N + 1) % 2 == 0: # Check if numtaps (N+1) is even
    N = N - 1 # Adjust N to make numtaps odd (3196 so numtaps becomes
3197)
print('Frecuencia de muestreo:', fs, "Hz")
print("Tamaño de la ventana:", ventana, "muestras")
print('Orden del filtro:', N)
```

```
b = firwin(
    numtaps=N + 1,
    cutoff=[lim_inf, lim_sup],
    fs=fs,
    window='blackman',
    pass_zero='bandstop'
)
a=[1]
w, h = freqz(b, worN=16384, fs=fs)
#filtro
x_filtrada_blackman = filtfilt(b, a, x)
#Espectrograma
f1, t1, Sxx1=spectrogram(
    x,
    fs=fs,
    nperseg=256,
    noverlap=128
)
f2, t2, Sxx2 = spectrogram(
    x_filtrada_blackman,
    fs=fs,
    nperseg=256,
    noverlap=128
)
#Grafica
vmin, vmax=-120, -20
fig, ax=plt.subplots(2, 1, figsize=(12, 8))
# Espectrograma original
im1 = ax[0].pcolormesh(
    t1,
    f1,
    10*np.log10(Sxx1 + 1e-12),
    shading='gouraud',
    vmin=vmin,
    vmax=vmax
)
ax[0].set_title('Espectrograma de la señal ruidosa')
ax[0].set_ylabel('Frecuencia [Hz]')
ax[0].set_ylim([0, 4000])
cbar1 = fig.colorbar(im1, ax=ax[0])
cbar1.set_label('Magnitud [dB]')
# Espectrograma filtrado
im2 = ax[1].pcolormesh(
    t2,
    f2,
    10*np.log10(Sxx2 + 1e-12),
    shading='gouraud',
    vmin=vmin,
    vmax=vmax
)
ax[1].set_title(
    'Espectrograma señal filtrada '
    '(FIR Blackman rechaza-banda, N = 6395)'
)
ax[1].set_xlabel('Tiempo [s]')
ax[1].set_ylabel('Frecuencia [Hz]')
ax[1].set_ylim([0, 4000])
cbar2 = fig.colorbar(im2, ax=ax[1])
cbar2.set_label('Magnitud [dB]')
plt.tight_layout()
plt.figure(figsize=(12, 5))
plt.plot(w, 20*np.log10(np.abs(h) + 1e-12))


plt.axvline(339, linestyle='--')
plt.axvline(439, linestyle='--')
plt.axvline(389, linestyle='--')
```

```
plt.xlim(300, 500)
plt.ylim(-100, 5)

plt.xlabel('Frecuencia [Hz]')
plt.ylabel('Magnitud [dB]')
plt.title('Respuesta en frecuencia - FIR Blackman rechaza-banda')
```


```
plt.grid()
plt.show()
# audios
print("Audio ruidoso:")
display(Audio(x, rate=fs))
print("Audio filtrado:")
display(Audio(x_filtrada_blackman, rate=fs))
```

Posteriormente obtenemos las siguientes gráficas:



Gráfica 12. Comparación Espectrograma Ruidoso y Filtrado

Al contrastar ambos espectrogramas, se evidencia una transformación drástica en la composición espectral de la señal, especialmente en la región inferior a los 500Hz. La franja de alta concentración de energía que representaba la interferencia tonal ha sido suprimida de manera efectiva, lo que confirma el desempeño del filtro FIR Blackman diseñado. Este cambio es notable a lo largo de toda la extensión temporal del audio, desde el segundo 0 hasta los 7,3s, demostrando que la componente estacionaria identificada en la fase de exploración fue eliminada satisfactoriamente en todo el registro



Gráfica 13. Filtro Rechaza Banda

Con esta gráfica se observa la frecuencia problemática en este caso de 389Hz la cual esta siendo atenuada y las bandas de rechazo las cuales son 339Hz y 439Hz. Verificando correctamente su funcionamiento.

- Para la implementación del filtro IIR, se seleccionó una topología Butterworth de orden 4 configurada como rechaza banda. Siguiendo la misma hipótesis de diseño, este filtro se implementó con un rango de corte entre 339 Hz y 439 Hz,

asegurando el ancho de banda de 100 Hz necesario para cubrir la ubicación de la interferencia detectada. Esta configuración se eligió por su respuesta máximamente plana en la banda de paso, lo que ayuda a preservar la calidad de la voz mientras se elimina el tono ruidoso.

El código implementado para este filtro es el siguiente:

```
import numpy as np
import matplotlib.pyplot as plt
import soundfile as sf
import librosa
from scipy.signal import butter, filtfilt, spectrogram, freqz
from IPython.display import Audio, display

# PARÁMETROS
fc_bajo = 339 # Frecuencia inferior de rechazo [Hz]
fc_alto = 439 # Frecuencia superior de rechazo [Hz]
orden = 4 # Orden del filtro Butterworth

# LECTURA DEL AUDIO
x_ruidosa_filepath = "D:/Users/ASUS/Downloads/audio_grupo_02.wav"
x, fs = librosa.load(
    x_ruidosa_filepath,
    sr=None
)

f_nyquist = fs / 2
print("FILTRO IIR BUTTERWORTH")
print("Frecuencia de muestreo:", fs, "Hz")
print("Orden:", orden)
print("Banda de rechazo:", fc_bajo, "-", fc_alto, "Hz")
print("Ancho de banda:", fc_alto - fc_bajo, "Hz")
print("Frecuencia central:",
      (fc_bajo + fc_alto) / 2, "Hz")

# NORMALIZACIÓN
fc_bajo_normalized = fc_bajo / f_nyquist
fc_alto_normalized = fc_alto / f_nyquist

# DISEÑO DEL BUTTERWORTH RECHAZA-BANDA
b, a = butter(
    N=orden,
    Wn=[fc_bajo_normalized, fc_alto_normalized],
    btype='bandstop'
)

# FILTRADO
x_filtrada_butterworth = filtfilt(
    b,
    a,
    x
)

# RESPUESTA EN FRECUENCIA
f_resp, H = freqz(
    b,
    a,
    worN=65536,
    fs=fs
)

H_dB = 20 * np.log10(
    np.maximum(np.abs(H), 1e-12)
)

plt.figure(figsize=(12, 6))
plt.plot(
    f_resp,
    H_dB
)

plt.title(
    'Respuesta en frecuencia - IIR Butterworth '
    f'(N = {orden})'
)

plt.xlabel('Frecuencia [Hz]')
plt.ylabel('Magnitud [dB]')
```

```

plt.xlim(250, 550)
plt.ylim(-100, 5)
plt.axvline(
    fc_bajo,
    linestyle='--',
    label='370 Hz'
)
plt.axvline(
    389,
    linestyle='--',
    label='389 Hz'
)
plt.axvline(
    fc_alto,
    linestyle='--',
    label='410 Hz'
)
plt.grid(True, alpha=0.3)
plt.legend()

plt.tight_layout()
plt.show()
# FFT ORIGINAL Y FILTRADA
NFFT = 2**18
X = np.fft.rfft(
    x,
    n=NFFT
)
Y = np.fft.rfft(
    x_filtrada_butterworth,
    n=NFFT
)
freqs = np.fft.rfftfreq(
    NFFT,
    1 / fs
)
X_dB = 20 * np.log10(
    np.maximum(np.abs(X), 1e-12)
)
Y_dB = 20 * np.log10(
    np.maximum(np.abs(Y), 1e-12)
)
plt.figure(figsize=(12, 6))
plt.plot(
    freqs,
    X_dB,
    label='Señal original'
)
plt.plot(
    freqs,
    Y_dB,
    label='Señal filtrada'
)
plt.xlim(250, 550)
plt.xlabel('Frecuencia [Hz]')
plt.ylabel('Magnitud [dB]')
plt.title(
    'FFT antes y después - IIR Butterworth'
)
plt.grid(True, alpha=0.3)
plt.legend()
plt.tight_layout()
plt.show()
# ESPECTROGRAMAS
f1, t1, Sxx1 = spectrogram(
    x,
    fs=fs,

```


```

    nperseg=1024,
    noverlap=768
)
f2, t2, Sxx2 = spectrogram(
    x_filtrada_butterworth,
    fs=fs,
    nperseg=1024,
    noverlap=768
)
vmin, vmax = -120, -20
fig, ax = plt.subplots(
    2,
    1,
    figsize=(12, 8)
)
# Original
im1 = ax[0].pcolormesh(
    t1,
    f1,
    10 * np.log10(Sxx1 + 1e-12),
    shading='gouraud',
    vmin=vmin,
    vmax=vmax
)
ax[0].set_title(
    'Espectrograma de la señal ruidosa'
)
ax[0].set_ylabel('Frecuencia [Hz]')
ax[0].set_ylim(0, 4000)

fig.colorbar(
    im1,
    ax=ax[0],
    label='Magnitud [dB]'
)
# Filtrada
im2 = ax[1].pcolormesh(
    t2,
    f2,
    10 * np.log10(Sxx2 + 1e-12),
    shading='gouraud',
    vmin=vmin,
    vmax=vmax
)
ax[1].set_title(
    f'Espectrograma filtrado - Butterworth '
    f'BSF, 370-410 Hz, N = {orden}'
)
ax[1].set_xlabel('Tiempo [s]')
ax[1].set_ylabel('Frecuencia [Hz]')
ax[1].set_ylim(0, 4000)
fig.colorbar(
    im2,
    ax=ax[1],
    label='Magnitud [dB]'
)
plt.tight_layout()
plt.show()
# audios
print("Audio ruidoso:")
display(Audio(x, rate=fs))
print("Audio filtrado:")
display(Audio(x_filtrada_butterworth, rate=fs))


```

Posteriormente obtenemos las siguientes gráficas:



Gráfica 14. Comparación Espectrograma Ruidoso y Filtrado

A través de la comparación de los espectrogramas, es posible notar el cambio drástico en la zona inferior a los 500Hz, donde la concentración de energía persistente que caracterizaba a la interferencia fue suprimida con éxito. Este efecto es claramente visible y se mantiene constante desde el inicio hasta el final del audio (0s a 7,3s), lo que ratifica que el filtro Butterworth cumple satisfactoriamente con el objetivo de eliminar la componente tonal estacionaria identificada sin afectar de manera notable el resto del espectro.



Gráfica 15. Filtro Rechaza Banda

Con esta gráfica se observa la frecuencia problemática en este caso de 389Hz la cual está siendo atenuada y las bandas de rechazo las cuales son 339Hz y 439Hz. Verificando correctamente su funcionamiento.

Localización automática mediante IA

Aplicación de DBSCAN, diseño de filtros y evaluación mediante máscara espectral


En esta etapa se implementó DBSCAN sobre el espectrograma de un audio con interferencia tonal. El objetivo fue localizar automáticamente la frecuencia de la interferencia, comparar la estimación con una medición manual y utilizar la frecuencia obtenida para diseñar filtros digitales y construir una máscara espectral para la evaluación objetiva.

Localización de la interferencia mediante DBSCAN


Se cargó el archivo Proyectos_Proyecto1_audio_grupo_02.wav. El audio se convirtió a punto flotante, se convirtió a mono cuando

fue necesario y se normalizó. Luego se calculó el espectrograma mediante una ventana Hann, con $n_{\text{perseg}} = 2048$ y $n_{\text{overlap}} = 1536$. Se analizaron frecuencias hasta 2000 Hz.

Para localizar las zonas de mayor energía se seleccionaron los puntos superiores al percentil 95 del espectrograma. Los puntos se normalizaron en tiempo y frecuencia y se agruparon mediante DBSCAN con $\text{eps} = 1.5$ y $\text{min_samples} = 8$. El cluster con mayor cantidad de puntos se tomó como la interferencia y su frecuencia se estimó mediante la mediana de sus frecuencias.



Gráfica 12. Espectrograma y frecuencia detectada mediante DBSCAN.



Gráfica 13. Puntos espectrales agrupados mediante DBSCAN.

Resultado: frecuencia manual = 389 Hz.

Frecuencia obtenida por DBSCAN = 387.60 Hz.

Diferencia = 1.40 Hz.

Error relativo = 0.36 %.

La presencia temporal estimada del cluster seleccionado fue aproximadamente de 0.05 a 7.57 s.

Código DBSCAN

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.io import wavfile
from scipy import signal
from sklearn.cluster import DBSCAN

archivo = "Proyectos_Proyecto1_audio_grupo_02.wav"
fs, audio = wavfile.read(archivo)
audio = audio.astype(float)
if audio.ndim > 1:
    audio = np.mean(audio, axis=1)

audio = audio / np.max(np.abs(audio))

f, t, S = signal.spectrogram(
    audio, fs=fs, window="hann",
```

```

nperseg=2048, noverlap=1536
)

Sdb = 10 * np.log10(S + 1e-12)

m = f <= 2000
f = f[m]
Sdb = Sdb[m, :]

umbral = np.percentile(Sdb, 95)
filas, columnas = np.where(Sdb >= umbral)

fp = f[filas]
tp = t[columnas]

X = np.column_stack((tp / 0.20, fp / 30.0))

db = DBSCAN(eps=1.5, min_samples=8)
labels = db.fit_predict(X)

clusters = []

for c in set(labels):
    if c == -1:
        continue
    idx = labels == c
    cantidad = np.sum(idx)
    frecuencia = np.median(fp[idx])

    clusters.append({
        "numero": c,
        "cantidad": cantidad,
        "frecuencia": frecuencia,
        "tiempo_min": np.min(tp[idx]),
        "tiempo_max": np.max(tp[idx])
    })

mejor = max(clusters, key=lambda x: x["cantidad"])

cluster_interferencia = mejor["numero"]
frecuencia_dbscan = mejor["frecuencia"]


frecuencia_manual = 389
diferencia = abs(frecuencia_manual - frecuencia_dbscan)
error = (diferencia / frecuencia_manual) * 100

print(f"Frecuencia manual: {frecuencia_manual} Hz")
print(f"Frecuencia DBSCAN: {frecuencia_dbscan:.2f} Hz")
print(f"Diferencia: {diferencia:.2f} Hz")
print(f"Error relativo: {error:.2f} %")


```

FILTRO FIR CON VENTANEO BLACKMAN

La frecuencia localizada mediante DBSCAN, 387.60 Hz, se utilizó como frecuencia central para diseñar un filtro FIR rechaza-banda. Se estableció un ancho de 15 Hz a cada lado, dando una banda de rechazo de 372.60 a 402.60 Hz. Se utilizaron 4001 coeficientes y una ventana Blackman. El audio filtrado se guardó como audio_filtrado_FIR_Blackman.wav.



Gráfica 14. Comparación del espectro antes y después del FIR Blackman.



Gráfica 15. Respuesta en frecuencia.

CODIGO FIR

```

import numpy as np
import matplotlib.pyplot as plt
from scipy.io import wavfile
from scipy import signal

archivo = "Proyectos_Proyecto1_audio_grupo_02.wav"
fs, audio = wavfile.read(archivo)
audio = audio.astype(float)

if audio.ndim > 1:
    audio = np.mean(audio, axis=1)

audio = audio / np.max(np.abs(audio))

frecuencia_dbscan = 387.60

ancho_banda = 15
f1 = frecuencia_dbscan - ancho_banda
f2 = frecuencia_dbscan + ancho_banda

numtaps = 4001

coeficientes = signal.firwin(
    numtaps=numtaps,
    cutoff=[f1, f2],
    window="blackman",
    pass_zero="bandstop",
    fs=fs
)

audio_filtrado = signal.filtfilt(
    coeficientes, [1.0], audio
)

```

```

audio_filtrado = np.clip(audio_filtrado, -1, 1)

archivo_salida = "audio_filtrado_FIR_Blackman.wav"
audio_int16 = np.int16(audio_filtrado * 32767)

wavfile.write(
    archivo_salida, fs, audio_int16
)

frecuencia_original, PSD_original = signal.welch(
    audio, fs=fs, nperseg=4096
)

frecuencia_filtrada, PSD_filtrada = signal.welch(
    audio_filtrado, fs=fs, nperseg=4096
)


PSD_original_db = 10 * np.log10(PSD_original + 1e-12)
PSD_filtrada_db = 10 * np.log10(PSD_filtrada + 1e-12)

plt.figure(figsize=(12, 6))
plt.plot(frecuencia_original, PSD_original_db,
         label="Audio original")
plt.plot(frecuencia_filtrada, PSD_filtrada_db,
         label="Audio filtrado FIR Blackman")
plt.axvline(frecuencia_dbscan, linestyle="--",
            linewidth=2,
            label=f"DBSCAN = {frecuencia_dbscan:.2f} Hz")
plt.axvspan(f1, f2, alpha=0.2,
            label="Banda de rechazo")
plt.xlim(0, 1000)
plt.xlabel("Frecuencia [Hz]")
plt.ylabel("Potencia [dB]")
plt.title("Comparación del espectro antes y después del filtro FIR
Blackman")
plt.grid(True, alpha=0.3)
plt.legend()
plt.tight_layout()
plt.show()


```

FILTRO IIR BUTTERWORTH

Se diseñó un filtro IIR Butterworth de orden 4, también como filtro rechaza-banda y utilizando la misma banda de 372.60 a 402.60 Hz. El audio resultante se exportó como `audio_filtrado_IIR_Butterworth.wav`. El uso de la misma banda permite comparar los dos tipos de filtros bajo condiciones similares.



Gráfica 16. Comparación del espectro antes y después del IIR Butterworth.



Gráfica 17. Respuesta en frecuencia.

CODIGO IRR

```

import numpy as np
import matplotlib.pyplot as plt
from scipy.io import wavfile
from scipy import signal

archivo = "Proyectos_Proyecto1_audio_grupo_02.wav"
fs, audio = wavfile.read(archivo)
audio = audio.astype(float)

if audio.ndim > 1:
    audio = np.mean(audio, axis=1)

audio = audio / np.max(np.abs(audio))

frecuencia_dbscan = 387.60

ancho_banda = 15
f1 = frecuencia_dbscan - ancho_banda
f2 = frecuencia_dbscan + ancho_banda

orden = 4

sos = signal.butter(
    orden, [f1, f2],
    btype="bandstop",
    fs=fs,
    output="sos"
)

audio_filtrado = signal.sosfiltfilt(sos, audio)
audio_filtrado = np.clip(audio_filtrado, -1, 1)

archivo_salida = "audio_filtrado_IIR_Butterworth.wav"
audio_int16 = np.int16(audio_filtrado * 32767)

```


```

wavfile.write(
    archivo_salida, fs, audio_int16
)

```

MASCARA ESPECTRAL

La máscara espectral se construyó alrededor de la frecuencia detectada por DBSCAN. Se utilizó la misma banda de 372.60 a 402.60 Hz para evaluar el audio original y los dos audios filtrados. Para cada caso se obtuvo el máximo nivel espectral dentro de la máscara y se calculó la atenuación respecto al audio original.



Gráfica 18. Mascara Espectral.

CODIGO

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.io import wavfile
from scipy import signal

archivo_original = "Proyectos_Proyecto1_audio_grupo_02.wav"
archivo_fir = "audio_filtrado_FIR_Blackman.wav"
archivo_iir = "audio_filtrado_IIR_Butterworth.wav"

frecuencia_dbscan = 387.60

ancho_mascara = 15
f1 = frecuencia_dbscan - ancho_mascara
f2 = frecuencia_dbscan + ancho_mascara

def cargar_audio(archivo):
    fs, audio = wavfile.read(archivo)
    audio = audio.astype(float)
    if audio.ndim > 1:
        audio = np.mean(audio, axis=1)
    audio = audio / np.max(np.abs(audio))
    return fs, audio

fs_original, audio_original = cargar_audio(archivo_original)
fs_fir, audio_fir = cargar_audio(archivo_fir)
fs_iir, audio_iir = cargar_audio(archivo_iir)

def calcular_espectro(audio, fs):
    f, Pxx = signal.welch(
        audio, fs=fs, nperseg=4096
    )
    Pxx_db = 10 * np.log10(Pxx + 1e-12)
    return f, Pxx_db

f_original, espectro_original = calcular_espectro(
    audio_original, fs_original
)
f_fir, espectro_fir = calcular_espectro(
    audio_fir, fs_fir
)
f_iir, espectro_iir = calcular_espectro(
    audio_iir, fs_iir
)

mascara_original = (
    (f_original >= f1) &
    (f_original <= f2)
)
mascara_fir = (
    (f_fir >= f1) &
    (f_fir <= f2)
)
mascara_iir = (
    (f_iir >= f1) &
```

```
(f_iir <= f2)
)

nivel_original = np.max(
    espectro_original[mascara_original]
)
nivel_fir = np.max(
    espectro_fir[mascara_fir]
)
nivel_iir = np.max(
    espectro_iir[mascara_iir]
)

atenuacion_fir = nivel_original - nivel_fir
atenuacion_iir = nivel_original - nivel_iir

print(f"Nivel original en la máscara: {nivel_original:.2f} dB")
print(f"Nivel después del FIR: {nivel_fir:.2f} dB")
print(f"Atenuación FIR: {atenuacion_fir:.2f} dB")
print(f"Nivel después del IIR: {nivel_iir:.2f} dB")
print(f"Atenuación IIR: {atenuacion_iir:.2f} dB")

plt.figure(figsize=(12, 6))
plt.plot(f_original, espectro_original,
         label="Audio original")
plt.plot(f_fir, espectro_fir,
         label="FIR Blackman")
plt.plot(f_iir, espectro_iir,
         label="IIR Butterworth")
plt.axvspan(f1, f2, alpha=0.25,
            label="Máscara espectral")
plt.axvline(frecuencia_dbscan,
            linestyle="--", linewidth=2,
            label=f"DBSCAN = {frecuencia_dbscan:.2f} Hz")
plt.xlim(0, 1000)
plt.xlabel("Frecuencia [Hz]")
plt.ylabel("Potencia [dB]")
plt.title("Evaluación objetiva mediante máscara espectral")
plt.grid(True, alpha=0.3)
plt.legend()
plt.tight_layout()
plt.show()
```

Parámetro	Resultado
Frecuencia manual	389 Hz
Frecuencia DBSCAN	387.60 Hz
Diferencia	1.40 Hz
Error relativo	0.36 %
Banda de máscara	372.60 – 402.60 Hz
Atenuación FIR Blackman	25.09 dB
Atenuación IIR Butterworth	19.75 dB
Mayor atenuación	FIR Blackman

EVALUACIÓN OBJETIVA DEL DESEMPEÑO

Comparación de los filtros FIR Blackman e IIR Butterworth

En esta etapa se evaluó cuantitativamente el desempeño de las soluciones implementadas en la Etapa 3. Para ello se utilizaron los audios original, filtrado mediante FIR Blackman y filtrado mediante IIR Butterworth. La frecuencia de interferencia

utilizada fue la obtenida automáticamente mediante DBSCAN: 387.60 Hz.


VENTANA DE EVALUACIÓN

De acuerdo con la guía, la energía residual de la interferencia se calcula dentro de una ventana de 100 Hz centrada en la frecuencia estimada mediante DBSCAN. Como la frecuencia detectada fue 387.60 Hz, los límites de la ventana son:

$$387.60 - 50 = 337.60 \text{ Hz}$$

$$387.60 + 50 = 437.60 \text{ Hz}$$

Por lo tanto, la evaluación se realizó en el intervalo $337.60 \text{ Hz} \leq f \leq 437.60 \text{ Hz}$.



Gráfica 19. Ventana de evaluación de 100 Hz.

INDICADORES UTILIZADOS

Se calcularon los tres indicadores establecidos por la guía:

E_residual: corresponde a la energía espectral ubicada dentro de la ventana de 100 Hz centrada en la frecuencia de interferencia.

E_voz: corresponde a la energía espectral conservada fuera de dicha ventana.

$$R = E_{\text{residual}} / E_{\text{voz}}$$

El indicador R permite comparar objetivamente las técnicas. Según la guía, un valor menor de R representa una menor energía residual de la interferencia respecto a la energía conservada y, por tanto, un mejor desempeño.

TABLA

Se cargaron los tres archivos de audio: el audio original `Proyectos_Proyecto1_audio_grupo_02.wav`, `audio_filtrado_FIR_Blackman.wav` y `audio_filtrado_IIR_Butterworth.wav`. Para cada uno se calculó el espectrograma y se separó la energía ubicada dentro y fuera de la ventana de evaluación. Finalmente se calculó R para cada técnica.

ETAPA 4: EVALUACIÓN OBJETIVA DEL DESEMPEÑO DE LAS SOLUCIONES

Comparación de las técnicas de filtrado implementadas

TÉCNICA DE FILTRADO	E_VOZ (Energía conservada fuera de la ventana)	E_RESIDUAL (Energía residual de la interferencia)	R (Indicador de desempeño)	REDUCCIÓN DE R (Respecto al original)
FIR Blackman IA (DBSCAN) 387.60 Hz	1,268840	8,135674e-02	6,411900e-02	78,04 %
FIR Blackman Manual 389 Hz	1,277400	8,380754e-02	6,560789e-02	77,53 %
IIR Butterworth Manual 389 Hz	1,276202	9,775926e-02	7,660169e-02	73,76 %
IIR Butterworth IA (DBSCAN) 387.60 Hz	1,261331	9,704510e-02	7,693866e-02	73,65 %

MEJOR ALTERNATIVA:
FIR BLACKMAN IA (DBSCAN)

Presenta el menor valor del indicador R, lo que representa el mejor desempeño de filtrado.

Los resultados muestran que ambos filtros reducen considerablemente el indicador R respecto al audio original.

COMPARACIÓN CUANTITATIVA

Tomando como referencia el audio original, el indicador R se redujo en 78.04% mediante el FIR Blackman y en 73.65% mediante el IIR Butterworth. Por tanto, el FIR consiguió una reducción mayor del indicador.

MEJOR ALTERNATIVA

Después de realizar la evaluación objetiva de las cuatro alternativas de filtrado implementadas, se determinó que la solución con mejor desempeño corresponde al filtro FIR Blackman diseñado utilizando la frecuencia identificada mediante DBSCAN, denominada en los resultados como FIR Blackman IA. Para realizar la comparación se utilizó la frecuencia de interferencia localizada automáticamente mediante DBSCAN, correspondiente a 387,60 Hz. De acuerdo con la metodología establecida para la Etapa 4, se tomó una ventana de evaluación de 100 Hz centrada en esta frecuencia, comprendida entre 337,60 Hz y 437,60 Hz. Dentro de esta ventana se evaluó la energía residual de la interferencia y, fuera de ella, la energía espectral conservada de la señal. Finalmente, estas dos cantidades permitieron obtener el indicador de desempeño R, cuyo menor valor representa la mejor alternativa.

Los resultados muestran una diferencia clara entre las cuatro técnicas. El filtro FIR Blackman diseñado con la frecuencia obtenida mediante DBSCAN presentó el menor valor del indicador R, con 0,064119. El segundo mejor resultado correspondió al FIR Blackman diseñado manualmente, con un valor de 0,065608. Por otro lado, los filtros IIR Butterworth presentaron valores superiores, de aproximadamente 0,07660 para la versión manual y 0,07694 para la versión basada en IA. Por lo tanto, el FIR Blackman IA obtuvo el indicador de desempeño más bajo de todas las alternativas. Esta diferencia es importante porque el indicador R relaciona la energía que permanece asociada a la interferencia con la energía que se

conserva fuera de la ventana de evaluación. En consecuencia, un menor valor indica que una proporción menor de la energía permanece asociada con la interferencia respecto a la señal conservada. Este es precisamente el criterio establecido en la guía para determinar la mejor solución. Otro aspecto que respalda la selección es la energía residual de la interferencia. El FIR Blackman IA obtuvo el menor valor entre las cuatro alternativas, aproximadamente 0,08136, mientras que el FIR Blackman manual presentó un valor cercano a 0,08381. Los filtros Butterworth tuvieron valores superiores, cercanos a 0,09776 para la versión manual y 0,09705 para la versión basada en DBSCAN. Esto indica que el FIR Blackman IA consiguió eliminar una mayor cantidad de la energía asociada con la interferencia dentro de la banda evaluada. En cuanto a la energía conservada fuera de la ventana, el FIR Blackman IA obtuvo aproximadamente 1,26884. Aunque el filtro FIR manual presentó una energía ligeramente superior, esto no significa que sea la mejor alternativa. La evaluación no busca únicamente conservar la mayor cantidad de energía posible, sino encontrar el mejor equilibrio entre la energía que permanece fuera de la interferencia y la energía residual que queda dentro de la banda contaminada. Por esta razón, el indicador R resulta fundamental para realizar la selección final. La comparación también permite observar una diferencia entre el diseño manual y el diseño apoyado por Inteligencia Artificial. Para el filtro FIR, utilizar la frecuencia obtenida mediante DBSCAN permitió mejorar el resultado respecto al diseño manual. El valor de R pasó de aproximadamente 0,06561 en el FIR manual a 0,06412 en el FIR basado en DBSCAN. Aunque la diferencia no es extremadamente grande, demuestra que la estimación automática de la frecuencia fue útil para realizar un ajuste más preciso de la solución. Este resultado es especialmente relevante porque una de las finalidades del proyecto consiste en integrar las herramientas clásicas de procesamiento digital de señales con Inteligencia Artificial. En la Etapa 3, la frecuencia encontrada mediante DBSCAN debía utilizarse como apoyo para el diseño del filtro y posteriormente mantenerse como referencia para la evaluación objetiva. En este caso, la integración de ambas herramientas produjo precisamente la alternativa con mejor desempeño.

Al comparar los resultados con la señal original también se observa una mejora considerable. La señal sin filtrar presentó un indicador R de aproximadamente 0,29194, mientras que el FIR Blackman IA redujo este valor hasta aproximadamente 0,06412. Esto representa una reducción del indicador de aproximadamente 78,04 % respecto a la señal original. Por tanto, la solución seleccionada consiguió disminuir significativamente la presencia de la interferencia dentro de la banda de interés. También resulta importante comparar el FIR Blackman con el IIR Butterworth. En ambas versiones, manual e IA, el FIR obtuvo un menor valor de R. Esto indica que, bajo las condiciones específicas de este experimento, el diseño FIR con ventana Blackman consiguió una mejor atenuación de la interferencia tonal que el filtro

Butterworth de orden cuatro. Además, la versión FIR basada en DBSCAN fue la que alcanzó el mejor resultado global.

Por estas razones, se selecciona el FIR Blackman IA como la mejor alternativa de filtrado. La decisión está sustentada en criterios cuantitativos y no únicamente en una apreciación subjetiva del audio. La técnica presentó la menor energía residual, el menor indicador R entre todas las soluciones y la mayor reducción del indicador respecto a la señal original.

IV. CONCLUSIONES

A. Se implementó una metodología para identificar y reducir una interferencia tonal presente en una señal de voz mediante la integración de técnicas de procesamiento digital de señales e inteligencia artificial. Los resultados obtenidos permitieron demostrar que la combinación de la detección automática mediante DBSCAN con el diseño de filtros digitales permitió mejorar la eliminación de la interferencia. La alternativa con mejor desempeño fue el filtro FIR Blackman basado en la frecuencia detectada automáticamente, el cual alcanzó un indicador R de aproximadamente 0,06412 y una reducción del 78,04 % respecto a la señal original. De esta manera, se cumplió el objetivo general al establecer una solución basada en criterios cuantitativos para identificar, reducir y seleccionar la alternativa de filtrado más eficiente.

B. Se analizó la señal de voz en los dominios del tiempo y la frecuencia, complementando este análisis con un espectrograma, lo que permitió formular una hipótesis inicial sobre la naturaleza y ubicación de la interferencia. En el dominio temporal se identificó una componente periódica y persistente, mientras que en el análisis espectral se localizó un pico alrededor de 389 Hz. El espectrograma confirmó además que dicha componente permanecía aproximadamente constante durante el registro, permitiendo caracterizarla como una interferencia tonal estacionaria.

C. Se diseñaron filtros FIR e IIR de tipo rechaza-banda utilizando los parámetros obtenidos durante el análisis inicial de la señal. Para el FIR se empleó una ventana de Blackman, mientras que para el IIR se utilizó una estructura Butterworth de orden 4. Ambas alternativas lograron atenuar considerablemente la componente tonal alrededor de 389 Hz, demostrando que los filtros diseñados fueron capaces de reducir la interferencia sin afectar de manera significativa el resto del espectro bajo las condiciones del experimento.

D. Se aplicó el algoritmo DBSCAN sobre el espectrograma para localizar automáticamente la frecuencia asociada a la interferencia tonal. El algoritmo obtuvo una frecuencia de 387,60 Hz frente a los 389 Hz determinados manualmente, presentando una diferencia de 1,40 Hz y un error relativo de 0,36 %. Este resultado evidenció que DBSCAN permitió realizar una estimación automática con una precisión suficiente para utilizar dicha frecuencia como parámetro en el rediseño de los filtros.

E. Se evaluó el desempeño de las alternativas de filtrado mediante indicadores matemáticos basados en la energía residual de la interferencia y la energía conservada de la señal. La comparación mostró que el FIR Blackman basado en DBSCAN obtuvo el menor indicador R, con aproximadamente 0,06412, seguido por el FIR Blackman diseñado manualmente con 0,06561. Los filtros

Butterworth presentaron valores superiores, por lo que, bajo las condiciones evaluadas, el FIR Blackman apoyado por DBSCAN constituyó la alternativa más eficiente para reducir la interferencia tonal.